



Tecnológico de Monterrey

Etapas 1. Conociendo el negocio

Aplicación de métodos multivariados en ciencia de datos (Gpo 101)

Equipo 3

Andrea Zavala Ruiz	A01571821
Valeria González Nava	A00842141
Adrian David Paez Parra	A00842372
César David Collins Estrada	A00841082

Profesores

Raúl Gómez Muñoz
Blanca Rosa Ruíz Hernández

Monterrey, NL

20 de agosto del 2026

Índice

Parte I. Conocimiento del negocio

Introducción y revisión bibliográfica

Descripción del socio formador

Descripción del problema

Pregunta de investigación

Objetivo general

Objetivos específicos

Justificación

Fuentes de información

Parte II. Comprensión y preparación de los datos

1. Resumen

2. Introducción

3. Ordenamiento de los datos

4. Identificación y eliminación de registros duplicados

5. Identificación de horas faltantes

6. Conversión de valores inválidos

7. Revisión de rangos operativos

8. Tratamiento de valores atípicos

9. Creación de variables derivadas

10. Transformación de la base a formato largo

11. Resumen del proceso de limpieza

12. Resultados obtenidos

Liga de GitHub a la base limpia

Declaratoria de uso de IA

Referencias

Parte I. Conocimiento del negocio

Introducción y revisión bibliográfica

La exposición a contaminantes en el aire puede tener efectos importantes en la salud. Las partículas PM10 pueden entrar profundamente en los pulmones y causar irritación e inflamación en las vías respiratorias. El ozono a nivel del suelo puede afectar el sistema respiratorio y contribuir a que aparezca o empeore el asma. Por estos riesgos la Organización Mundial de la Salud establece guías basadas en evidencia para orientar el monitoreo y la regulación de la calidad del aire, así como para reducir la exposición de la población a contaminantes como PM10 y O (Organización Mundial de la Salud [OMS], 2021).

Este problema también es importante en el contexto local. En el Área Metropolitana de Monterrey, un estudio realizado con datos de ocho municipios entre 2016 y 2019 encontró asociaciones entre el aumento de distintos contaminantes y el número diario de ingresos hospitalarios. Entre los contaminantes analizados PM10 y O fueron los únicos que superaron los valores máximos permitidos por las normas mexicanas. Además, el grupo de 5 a 59 años presentó una mayor vulnerabilidad, lo cual fue relacionado por los autores con la movilidad y el tiempo de exposición de estudiantes y personas económicamente activas. Aunque los índices de riesgo encontrados fueron bajos, los resultados siguen siendo importantes para la salud pública y pueden servir para desarrollar políticas que protejan a las personas más expuestas (Cerón Breton et al., 2021).

Otros estudios realizados en Monterrey muestran que las concentraciones de PM10 cambian según el momento, la ubicación y las condiciones meteorológicas. González-Santiago et al. (2011) analizaron datos del SIMA de 2006 a 2008 y compararon las concentraciones entre estaciones de monitoreo, temporadas, días y horas mediante estadística descriptiva, pruebas de diferencias y rosas de los vientos. Sus resultados mostraron que el invierno fue la temporada con mayor contaminación y que las concentraciones más altas se presentaron durante la mañana. También encontraron una relación negativa entre la velocidad del viento y el PM10 en la mayoría de las zonas, esto quiere decir que cuando el viento tiene menor velocidad puede ser más difícil que las partículas se dispersen. La zona suroeste presentó los niveles más elevados, posiblemente por la combinación de las emisiones, la dirección del viento y las barreras topográficas. Fajardo-Montiel y Ramírez-Sánchez (2023), analizaron datos horarios, diarios, mensuales y anuales de distintas estaciones del SIMA y también identificaron variaciones relacionadas con la temporada, el viento, la forma del terreno y diferentes actividades humanas.

En el caso del ozono, las condiciones meteorológicas y la presencia de otros contaminantes pueden influir en su comportamiento. En un estudio realizado en Cadereyta, Nuevo León, Jaramillo-Perez et al. (2025) utilizaron correlaciones de Spearman y regresión lineal múltiple para analizar el O junto con NO, NO₂, NO_x y distintas variables meteorológicas. Los resultados mostraron que el ozono aumentaba cuando la temperatura era mayor y disminuía cuando aumentaba la humedad relativa. También encontraron que el efecto de los óxidos de nitrógeno y de las condiciones meteorológicas cambiaba según la temporada del año. Estos estudios muestran que PM10 y O no deben estudiarse de manera aislada, sino considerando el momento,

la ubicación y las condiciones meteorológicas.

A partir de esta problemática, el proyecto propone estudiar la relación entre las condiciones meteorológicas y las concentraciones de PM10 y ozono (O) registradas por el SIMA durante 2025. El análisis tomará en cuenta las posibles diferencias entre periodos del año y estaciones de monitoreo de la Zona Metropolitana de Monterrey.

Descripción del socio formador

El Sistema Integral de Monitoreo Ambiental (SIMA) es la red que se encarga de medir y vigilar la calidad del aire en Nuevo León. Forma parte de la Secretaría de Medio Ambiente del estado y reúne información sobre las concentraciones de distintos contaminantes y sobre las condiciones meteorológicas. Su objetivo es conocer la calidad del aire que respira la población e identificar los momentos en los que la contaminación alcanza niveles elevados (Secretaría de Medio Ambiente de Nuevo León, s. f.).

Para obtener esta información, el SIMA cuenta con estaciones de monitoreo ubicadas en diferentes puntos de la Zona Metropolitana de Monterrey. Estas estaciones miden contaminantes como PM10, PM2.5, O, CO, NO, NO₂, NO_x y SO₂. También registran la temperatura, la humedad, la presión atmosférica, la lluvia, la radiación solar y la velocidad y dirección del viento. Antes de utilizarse, los datos pasan por un proceso de revisión y validación. Después sirven para crear indicadores y reportes que informan sobre la calidad del aire (Sistema Integral de Monitoreo Ambiental, 2024).

El trabajo de la Secretaría de Medio Ambiente no solamente es publicar estas mediciones, sino que también cuenta con áreas que estudian cómo se comporta y se mueve la contaminación, así como áreas encargadas de vigilar las emisiones de industrias, vehículos y otras fuentes. De esta forma la información obtenida puede utilizarse para conocer el comportamiento de los contaminantes, detectar riesgos y apoyar acciones para prevenir y controlar la contaminación del aire (Secretaría de Medio Ambiente de Nuevo León, s. f.).

El trabajo del SIMA es importante para este proyecto porque proporciona los datos que se necesitan para comparar la calidad del aire en diferentes estaciones y momentos del año. Sus mediciones permitirán estudiar cómo se relacionan las condiciones meteorológicas con las concentraciones de PM10 y O durante 2025. Los resultados pueden ayudar a reconocer los periodos, condiciones y zonas que podrían requerir mayor atención.

Descripción del problema

Las concentraciones de contaminantes atmosféricos no permanecen constantes, sino que cambian según el lugar, el momento y las condiciones meteorológicas. Factores como la temperatura, humedad, radiación solar, precipitación, velocidad y dirección del viento pueden favorecer la formación, acumulación, transporte o dispersión de determinados contaminantes.

Esta variabilidad se agrava en el caso del Área Metropolitana de Monterrey ya que la ciudad está rodeada de montañas que actúan como barreras naturales, lo que junto con la dirección del viento y la estabilidad atmosférica favorece a la acumulación de contaminantes en lugar de su dispersión (AMCHAM México, 2025). Un fenómeno particularmente relevante es la

inversión térmica, que ocurre cuando una masa de aire cálido se sitúa sobre una capa de aire más frío cerca de la superficie, actuando como una especie de tapa que impide el ascenso y la mezcla vertical de los contaminantes. En Monterrey este fenómeno se presenta con mayor frecuencia entre los meses de otoño e invierno, coincidiendo con los periodos de mayores concentraciones registradas por el SIMA (Mayora, 2019).

Este comportamiento hace que la contaminación del aire en Monterrey no pueda entenderse como un problema homogéneo en el tiempo o el espacio, sino como un fenómeno que depende de la interacción entre la topografía de la cuenca, las condiciones meteorológicas y la localización de las estaciones de monitoreo. Comprender esta interacción es el punto de partida de este proyecto, que se enfoca en las concentraciones de PM10 y ozono (O) registradas por el SIMA durante 2025, considerando las posibles diferencias entre periodos del año y estaciones de monitoreo de la Zona Metropolitana de Monterrey.

El proyecto propone concentrarse en PM10 y O porque ambos son relevantes para la calidad del aire y presentan una cobertura relativamente alta en la base de datos de 2025. Además, representan fenómenos distintos: el PM10 corresponde a partículas suspendidas, mientras que el O es un contaminante secundario cuya formación puede ser favorecida por determinadas condiciones atmosféricas.

Pregunta de investigación

¿Cómo se relacionan la temperatura, humedad relativa, radiación solar, precipitación, velocidad y dirección del viento con las concentraciones horarias de PM10 y O en las estaciones de monitoreo de la Zona Metropolitana de Monterrey durante 2025?

Objetivo general

Analizar la relación entre las condiciones meteorológicas y las concentraciones horarias de PM10 y O registradas en las estaciones de monitoreo de la Zona Metropolitana de Monterrey durante 2025, para identificar patrones temporales y diferencias entre estaciones.

Objetivos específicos

1. Describir el comportamiento de las concentraciones de PM10 y O según la hora, el mes y la estación de monitoreo.
2. Analizar la relación del PM10 con la humedad, lluvia, temperatura, velocidad y dirección del viento.
3. Analizar la relación del O con la temperatura, radiación solar, humedad y el viento.
4. Comparar los patrones observados entre las distintas estaciones de monitoreo.
5. Evaluar la calidad de los datos mediante la identificación de valores faltantes, duplicados y registros fuera de los rangos operativos.

Justificación

La relevancia de PM10 y O no es sólo metodológica, sino que responde a evidencia consolidada sobre sus efectos en la salud. La NOM-025-SSA1-2021 reconoce una relación causal entre la exposición a partículas suspendidas y el incremento de enfermedades cardiovasculares, cerebrovasculares y respiratorias, además de efectos en población infantil como bajo peso al nacer y mayor prevalencia de asma (Secretaría de Salud, 2021). En el caso del ozono, su exposición se ha asociado con el agravamiento de padecimientos respiratorios como el asma (OMS, 2021).

Este respaldo científico tiene además un correlato normativo: la NOM-172-SEMARNAT-2019 obliga a los sistemas de monitoreo estatales, incluido el SIMA, a reportar de forma horaria el estado de la calidad del aire y el riesgo a la salud para PM10 y O, junto con otros cuatro contaminantes criterio (SEMARNAT, 2019). Esto nos confirma que ambos contaminantes están sujetos a un marco regulatorio activo orientado a la protección de la población, lo que da utilidad práctica al proyecto más allá del enfoque académico.

Sin embargo, los antecedentes revisados (González-Santiago et al., 2011; Fajardo-Montiel y Ramírez-Sánchez, 2023; Jaramillo-Pérez et al., 2025) se concentran en periodos anteriores a 2020 o en zonas específicas como Cadereyta, por lo que no tenemos un análisis actualizado que integre las 15 estaciones de monitoreo de la ZMM con datos de 2025.

Se propone trabajar con PM10 y O porque ambos son contaminantes relevantes y cuentan con suficiente disponibilidad de información en la base de 2025. El PM10 tiene aproximadamente 95.2% de datos disponibles, mientras que el O tiene aproximadamente 93.4%.

Este enfoque permite estudiar la relación entre la contaminación y diferentes condiciones atmosféricas sin abarcar simultáneamente todos los contaminantes disponibles. Asimismo, hace posible realizar comparaciones temporales y geográficas con un alcance adecuado para la extensión solicitada.

Fuentes de información

El proyecto utilizará la base de datos de contaminantes y parámetros meteorológicos del SIMA correspondiente a 2025. Esta contiene información horaria organizada en 15 estaciones de monitoreo e incluye mediciones de contaminantes y variables meteorológicas.

También se utilizarán el diccionario de etiquetas, los rangos operativos de los parámetros del SIMA y el documento con la ubicación, coordenadas y elevación de las estaciones.

Parte II. Comprensión y preparación de los datos

1. Resumen

El presente reporte documenta el proceso de limpieza, validación y preparación de la base de datos correspondiente al año 2025 del Sistema Integral de Monitoreo Ambiental (SIMA). La información original se encuentra distribuida en distintas hojas de un archivo de Excel, donde cada hoja representa una estación de monitoreo.

El objetivo principal fue integrar todas las estaciones en una sola base, ordenar los registros, detectar posibles errores, completar la estructura temporal, identificar valores inválidos y preparar los datos para análisis posteriores. Todo el procedimiento se realizó en R mediante diferentes herramientas para la manipulación, limpieza y organización de datos.

2. Introducción

Primero se preparó el entorno de trabajo descargando las librerías necesarias. Utilizamos como base original el archivo correspondiente a los datos de 2025. De este, se obtuvieron los nombres de todas las hojas disponibles en el archivo, importando cada una de ellas, además de añadir una nueva variable llamada "estación" y que corresponde al nombre de la hoja de origen.

De esta manera, todas las estaciones quedaron integradas en una sola base de datos. Finalmente se revisaron las dimensiones de la base, las variables, y elementos generales para confirmar que la importación se haya realizado correctamente.

La base unida originalmente contenía 131,378 registros y 17 variables, incluyendo la estación y la fecha. Después de completar las horas faltantes y crear seis variables temporales, la base final quedó formada por 131,400 registros y 23 variables. En total, el 10.79% de las mediciones quedó registrado como valor faltante.

3. Ordenamiento de los datos

Una vez integradas las estaciones, se ordenaron los registros por estación y por fecha, así mantuvimos una secuencia cronológica para cada estación, lo que nos facilita identificar problemas como duplicidad de registros o fechas desordenadas. Se revisaron también las primeras y últimas observaciones para comprobar que la organización de los registros fuera correcta.

4. Identificación y eliminación de registros duplicados

El siguiente paso consistió en revisar los registros duplicados, y en caso de que existieran, darles un manejo adecuado. Para esto identificamos los registros cuya estación y fecha aparecieran más de una vez. Con los registros que cumplieran esto, se hizo una revisión de cada uno y se conservó únicamente una observación. Con esto pudimos calcular la cantidad total de registros duplicados y el porcentaje que estos representan del total de registros.

5. Identificación de horas faltantes

A continuación se revisó la continuidad temporal de los registros. Por cada estación se identificó la fecha inicial, la cantidad de horas registradas y el número de horas faltantes. Asimismo se generó una estructura con todas las horas que deberían existir en el periodo de tiempo correspondiente (01/01/2025 00:00 - 31/12/2025 23:00). Las horas que no aparecían en la base original fueron agregadas como nuevas filas con el fin de mantener una correcta continuidad temporal. De igual manera, los datos de estas filas creadas permanecen como faltantes o NA.

6. Conversión de valores inválidos

Fue necesario identificar qué valores de los parámetros ambientales no representaban mediciones válidas, en este caso buscábamos valores tales como ND, NULL, celdas vacías, -999 o similares. Estos valores se sustituyeron por NA y se convirtieron los parámetros a formato numérico.

7. Revisión de rangos operativos

Cada variable cuenta con un valor mínimo y máximo permitidos, los valores fuera de estos rangos se consideraron inválidos y sustituidos con NA, lo que correspondían a posibles errores de captura o funcionamiento.

8. Tratamiento de valores atípicos

Se calcularon el primer y tercer cuartil de cada parámetro para conocer la distribución de los datos y observar valores alejados del comportamiento general. Sin embargo no se eliminaron observaciones solamente por ser estadísticamente atípicas, ya que en los datos ambientales pueden existir picos reales de contaminación. Por esta razón únicamente se convirtieron en NA los valores que se encontraban fuera de los rangos operativos establecidos. Los valores atípicos que permanecían dentro de estos rangos se conservaron.

9. Creación de variables derivadas

Después de la limpieza de la base de datos, generamos nuevas variables a partir de la fecha y hora de cada observación. Entre las variables generadas estaban año, mes, día de la semana, hora del día, estación del año y periodo del día. Las estaciones del año fueron clasificadas en: invierno de diciembre a febrero, primavera de marzo a mayo, verano de junio a agosto y otoño de septiembre a noviembre. Las horas del día fueron clasificadas como mañana de 6:00 a 11:59 hrs, tarde de 12:00 a 18:59 hrs y noche de 19:00 a 5:59 hrs.

Estas variables nos permitirán realizar análisis temporales de nuestros parámetros ambientales con mayor facilidad.

10. Transformación de la base a formato largo

Una vez finalizada la limpieza, la base fue modificada de un formato ancho a uno largo, terminando con una estructura donde cada observación contiene información sobre la estación, fecha, parámetro, variables temporales y los valores registrados.

Finalmente, se exportó la base final en un archivo independiente.

11. Resumen del proceso de limpieza

Durante este proceso de limpieza pudimos calcular diversos indicadores para conocer qué tanto se modificó la base de datos durante la limpieza. En la siguiente tabla se muestran los principales resultados a reportar:

Métrica	Resultado
Registros originales	131,378
Duplicados eliminados	0
Porcentaje de duplicados eliminados	0%
Filas horarias agregadas	22
Registros finales	131,400
Valores fuera de rango convertidos en NA	401
Porcentaje de mediciones fuera de rango	0.02%
Porcentaje final de valores faltantes	10.79%

El porcentaje final de datos faltantes representa la proporción de celdas que terminaron con un valor NA después del proceso de limpieza.

12. Resultados obtenidos

Una vez terminado el proceso, la base de datos final tiene las siguientes características:

- Los registros quedaron ordenados por estación y fecha de captura del valor.
- Cada estación cuenta con 8,760 horas registradas.
- Los valores inválidos y valores fuera de los rangos operativos se sustituyeron con NA.
- Se conservaron los datos atípicos físicamente posibles.
- Se añadieron variables temporales para próximos análisis.

Liga de GitHub a la base limpia

https://github.com/D4rthCollins/Eq3_2003B/blob/trunk/data/datos_sima_2025_limpio_largo.csv.gz

Además los archivos se encuentran en el repositorio del proyecto: https://github.com/D4rthCollins/Eq3_2003B/tree/trunk

Declaratoria de uso de IA

Opción B: se utilizó IA

1. **Herramienta:** ChatGPT, Claude
2. **Uso realizado:** Apoyo para mejorar la redacción y código en R, así como para organizar el proceso de limpieza de datos.
3. **Secciones donde se utilizó:** Redacción del reporte y preparación de los datos.
4. **Validación realizada:** El equipo revisó la información, ejecutó el código y comprobó directamente los resultados obtenidos.

5. **Responsabilidad:** El contenido final fue revisado y verificado por el equipo, que asume la responsabilidad de la información entregada.
6. **Otro:** La herramienta se utilizó como apoyo y no sustituyó la revisión.

Referencias

1. Cerón Breton, R. M., Céron Breton, J., de la Luz Espinosa Fuentes, M., Kahl, J., Espinosa Guzman, A. A., Martínez, R. G., Guarnaccia, C., del Carmen Lara Severino, R., Ramirez Lara, E., & Francavilla, A. B. (2021). Short-Term Associations between Morbidity and Air Pollution in Metropolitan Area of Monterrey, Mexico. *Atmosphere*, 12(10), 1352. <https://doi.org/10.3390/atmos12101352>
2. Comisión Ambiental de la Megalópolis. (s. f.). *Coinciden los sectores ambiental y de salud en integrar una agenda de gestión de la calidad del aire y la protección a la salud*. Gobierno de México. <https://www.gob.mx/comisionambiental/prensa/coinciden-los-sectores-ambiental-y-de-salud-en-integrar-una-agenda-de-gestion-de-la-calidad-del-aire-y-la-proteccion-a-la-salud>
3. *Estructura orgánica / Secretaría de Medio Ambiente / Gobierno del Estado de Nuevo León*. (2024). Nl.Gob.Mx. <https://www.nl.gob.mx/es/estructura-organica/medioambiente>
4. Fajardo-Montiel, A. L., & Ramírez-Sánchez, H. U. (2023). Evolution of air pollution in the Monterrey Metropolitan Area, Mexico. *Asian Journal of Environment & Ecology*, 21(1), 55-75. <https://doi.org/10.9734/ajee/2023/v21i1453>
5. Gobierno del Estado de Nuevo León. (s.f.). *Sistema Integral de Monitoreo Ambiental (SIMA)*. Recuperado el 18 de agosto de 2026, de <https://aire.nl.gob.mx/>
6. González-Santiago, O., Badillo-Castañeda, C. T., Jonathan D.W. Kahl, Ramírez-Lara, E., & Balderas-Renteria, I. (2011, October 10). *Temporal Analysis of PM10 in Metropolitan Monterrey, México*. Journal of the Air & Waste Management Association; Taylor & Francis. <https://www.tandfonline.com/doi/full/10.3155/1047-3289.61.5.573>
7. Jaramillo-Perez, J. M., Macías-Hernández, B. A., Tello-Leal, E., & Ventura-Houle, R. (2025). Effect of nitrogen oxide concentration levels and meteorological variables on ozone (O) formation in the petrochemical industry area in the Monterrey Metropolitan, Mexico. *Environmental and Earth Sciences Proceedings*, 34(1), 3. <https://doi.org/10.3390/eesp2025034003>
8. Secretaría de Medio Ambiente y Recursos Naturales. (2019, 20 de noviembre). *Norma Oficial Mexicana NOM-172-SEMARNAT-2019, Lineamientos para la obtención y comunicación del Índice de Calidad del Aire y Riesgos a la Salud*. Diario Oficial de la Federación. https://www.dof.gob.mx/nota_detalle.php?codigo=5579387&fecha=20/11/2019

9. Secretaría de Salud. (2021, 27 de octubre). *Norma Oficial Mexicana NOM-025-SSA1-2021, Salud ambiental. Criterio para evaluar la calidad del aire ambiente, con respecto a las partículas suspendidas PM10 y PM2.5*. Diario Oficial de la Federación. <https://sidof.segob.gob.mx/notas/docFuente/5633855>
10. Sistema Integral de Monitoreo Ambiental. (2024). *Reporte de la meteorología y calidad del aire en la Zona Metropolitana de Monterrey: octubre de 2024*. Secretaría de Medio Ambiente de Nuevo León. https://aire.nl.gob.mx/docs/reportes/mensuales/2024/10_Reporte_Octubre_2024.pdf
11. World Health Organization: WHO. (2021, September 22). *What are the WHO Air quality guidelines?* Who.Int; World Health Organization: WHO. <https://www.who.int/news-room/feature-stories/detail/what-are-the-who-air-quality-guidelines>