



Tecnológico de Monterrey

Etapas 2. Conociendo los datos

Aplicación de métodos multivariados en ciencia de datos (Gpo 101)

Andrea Zavala Ruiz | A01571821

Valeria González Nava | A00842141

Adrian David Paez Parra | A00842372

César David Collins Estrada | A00841082

Profesores

Raúl Gómez Muñoz

Blanca Rosa Ruíz Hernández

Monterrey, NL

27 de agosto del 2026

Índice

Objetivo del análisis	3
Técnicas Estadísticas	3
Comprensión de los datos	4
a) Dimensión del dataset	4
b) Descripción de variables	5
Análisis Exploratorio	5
1) Medidas estadísticas	5
Variables cuantitativas	5
2) Exploración visual	6
Matrices de correlación	6
Boxplots	6
Análisis de distribución de los datos (Histogramas anexo E)	6
Verificación de la calidad de los datos	7
Resumen	7
Logrado hasta ahora	7
Camino a seguir	7
Liga de GitHub a la base limpia	8
Declaratoria de uso de IA	8
Referencias	9
Anexos	10
Anexo A. Resumen general de la base de datos	10
Anexo B. Horas faltantes por año y estación	10
Anexo C. Matrices de correlación por estación	11
Anexo D. Boxplots	11
Anexo E. Histogramas	12

Objetivo del análisis

El objetivo no cambió respecto a la propuesta inicial: analizar la relación entre las condiciones meteorológicas y las concentraciones horarias de PM 2.5, PM10 y O₃ en la Zona Metropolitana de Monterrey, para identificar patrones temporales y diferencias entre estaciones de monitoreo.

Lo que sí se ajustó fue el alcance de los datos, no el objetivo:

- Se pasó de trabajar con las 15 estaciones de la red SIMA a solo 3 estaciones (SO, SE3, NTE2), justificado por calidad de datos y representatividad de distintas zonas de la ciudad.

Las estaciones SO, SE3 y NTE2 se eligieron por dos criterios combinados: calidad de datos (son las tres con menor porcentaje de valores faltantes de toda la red) y representatividad de distintos contextos ambientales de la ciudad, verificado con fuentes oficiales y periodísticas: SE3 (Cadereyta Jiménez): sede de la refinería de Pemex, identificada como la principal fuente fija de contaminantes de la zona metropolitana (EGADE Business School, s.f.). NTE2 (San Nicolás de los Garza): zona urbana con presencia industrial metalúrgica cercana (El Horizonte, 2025). y SO (Santa Catarina) como zona con fuerte presión de emisiones de partículas por actividad de canteras, señalada como una fuente relevante de PM10 en la ZMM (Verificado.mx, 2023).

Esto permite comparar patrones de contaminación entre zonas con influencias distintas, en lugar de comparar estaciones geográficamente similares.

- Se amplió el periodo de 2025 completo a 2024-2025 (año y medio), ya que 2025 por sí solo cubre medio año de información. Con ambos años se obtiene una muestra más completa para el análisis de patrones estacionales y temporales.

Técnicas Estadísticas

A partir de la indagación bibliográfica realizada, se identificaron las siguientes técnicas:

- Estadística descriptiva (medias, medianas, desviación estándar, distribución por hora/mes/estación): para el objetivo 1, describir el comportamiento de PM 2.5, PM10 y O₃.
- Regresión lineal múltiple (OLS): modelo base para cuantificar la relación de PM 2.5, PM10 y O₃ con las variables meteorológicas (objetivos 2 y 3).
- Prueba de Durbin-Watson: diagnóstico para detectar autocorrelación temporal en los residuos del modelo, dado que los datos son series de tiempo horarias (Durbin & Watson, 1951).
- Errores estándar robustos HAC (Newey-West): corrección aplicada al modelo de regresión para obtener inferencia estadística válida cuando existe autocorrelación, sin necesidad de cambiar la estimación de los coeficientes (Newey & West, 1987).

Estas técnicas en conjunto permiten describir, cuantificar y validar estadísticamente las relaciones que pide el objetivo, manejando correctamente el hecho de que los datos horarios de contaminación no son observaciones independientes.

Se decidió no imputar los datos faltantes y dejarlos como NA, por tres razones principales: (1) el porcentaje de faltante en las 3 estaciones es bajo (menos de 2%), por lo que no es necesario "rellenar" datos para tener una muestra suficiente; (2) imputar (por ejemplo, con promedios o interpolación) inserta valores estimados que podrían distorsionar justamente la relación meteorología-contaminante que se busca medir; y (3) los modelos de regresión que se usarán excluyen automáticamente las observaciones con datos faltantes (listwise deletion), lo cual es un tratamiento estándar y aceptado cuando el faltante es bajo (Little & Rubin, 2019).

Comprensión de los datos

a) Dimensión del dataset

La base contiene 39,236 registros y 18 columnas. Cada registro representa una medición horaria de una de las estaciones NTE2, SE3 o SO. El periodo estudiado comprende todo 2024 y el primer semestre de 2025.

b) Descripción de variables

Variable	Descripción	Tipo	Valores posibles	Nulos
año	año de la medición	Categorico	2024, 2025	0
estacion	estación de monitoreo	Categorico	NTE2, SE3, SO	0
date	fecha y hora del registro	Categorico/tempo- ral	Ene. 2024-jun. 2025	0
O3	concentración de ozono	Numérico	1-168 y NA	1,520
PM10	partículas menores a 10 µm	Numérico	1-811 y NA	1,103
PM2.5	partículas menores a 2.5 µm	Numérico	1-483 y NA	5,603
NO / NO2/ NOX	Oxidos de nitrógeno	Numérico	Valores continuos y NA	990 / 855/ 859
CO	concentración de monóxido de carbono	Numérico	Valores continuos y NA	2,112

SO2	concentración de dióxido de azufre	Numérico	Valores continuos y NA	720
TOUT	temperatura exterior	Numérico	Valores continuos y NA	1,596
RH	humedad relativa	Numérico	Valores continuos y NA	2,960
WSR	velocidad del viento	Numérico	Valores continuos y NA	1,721
WDR	dirección del viento	Numérico	0°-360° y NA	1,608
PRS	presión atmosférica	Numérico	Valores continuos y NA	2,005
RAINF	precipitación	Numérico	Valores continuos y NA	1,375
SR	radiación solar	Numérico	Valores continuos y NA	575

Análisis Exploratorio

1) Medidas estadísticas

Variables cuantitativas

Medidas de tendencia central

Variable	Promedio/Me- dia	Mediana	Moda
O ₃	27.24	23.00	2.00
PM10	67.53	55.00	46.00
PM2.5	22.41	18.41	8.00

Medidas de dispersión

Variable	Rango (máx-mín)	Varianza	Desviación estándar
O ₃	167	420.21	20.50
PM10	810	2,529.18	50.29
PM2.5	482	318.62	17.85

En los tres contaminantes el promedio fue mayor que la mediana. Esto indica que algunos valores altos empujan el promedio hacia arriba. PM10 presentó la mayor dispersión.

Variables cualitativas

Distribución por año

Año	Frecuencia	Porcentaje
2024	26,348	67.15%
2025	12,888	32.85%

Distribución por estación

Estación	Frecuencia	Porcentaje
NTE2	13,125	33.45%
SE3	13,125	33.45%
SO	12,986	33.10%

Las estaciones tienen una representación equilibrada. La diferencia entre años se debe a que 2024 está completo y 2025 solamente incluye seis meses.

Mediana en escala ordinal: no aplica, porque la estación es una variable nominal sin un orden natural.

2) Exploración visual

Variables cuantitativa

Medidas de posición no-central

Medida	O₃	PM10	PM2.5
Q1	12.00	38.00	11.00
Q2	23.00	55.00	18.41
Q3	38.00	82.00	30.00
Outliers	988	2,191	1,116

Los valores atípicos se identificaron mediante el criterio de $1.5 \times IQR$. No se eliminaron automáticamente porque pueden representar episodios reales de contaminación.

Matrices de correlación

Se generaron matrices de correlación de Pearson ([ver Anexo C](#)) entre O₃, PM10, PM2.5, precursores (NO, NO₂, NO_x, CO, SO₂) y variables meteorológicas (TOUT, RH, WSR, WDR, PRS, RAINF, SR) para cada una de las tres estaciones (SO, SE3, NTE2) por separado. El hallazgo principal: O₃ mostró relación positiva consistente con temperatura y radiación solar, y negativa con humedad relativa en las tres estaciones; las correlaciones de PM10 y PM2.5 con las variables meteorológicas fueron más débiles y su signo/magnitud cambió entre estaciones, lo que respalda analizar cada estación de forma independiente en las siguientes etapas

Boxplots

Los boxplots ([Anexo D](#)) muestran distribuciones con colas largas y varios valores atípicos altos. PM10 presenta la mayor cantidad de valores extremos.

Análisis de distribución de los datos (Histogramas [anexo E](#))

Los tres contaminantes presentan asimetría positiva. La mayoría de las observaciones se concentra en valores bajos o moderados pero existen algunos valores muy elevados.

Las estaciones aportan cantidades similares de registros. El mayor número de observaciones de 2024 se debe a que incluye doce meses mientras que 2025 incluye seis.

Verificación de la calidad de los datos

También se detectaron dos mediciones físicamente inválidas, un valor de -9 en O_3 y uno de -1 en $PM_{2.5}$. Además se corrigió un desfase de seis horas causado por la zona horaria.

Los valores negativos de O_3 y $PM_{2.5}$ se convirtieron en NA, ya que las concentraciones no pueden ser negativas. El desfase temporal se corrigió utilizando la zona horaria de Monterrey sin modificar la hora registrada originalmente.

Resumen

Logrado hasta ahora

- Análisis exploratorio completo de la base: dimensión, tipos de variable, estadística descriptiva y correlaciones por estación.
- Evaluación de calidad de datos (faltantes, duplicados, valores inválidos, desfase horario) y su corrección.
- Justificación documentada de la reducción de 15 a 3 estaciones (NTE2, SE3, SO) y de la ampliación del periodo a 2024-2025.
- Identificación, durante la evaluación de calidad de datos, de un faltante crítico en humedad relativa (71.52%) en la estación SO, y definición de cómo tratarlo en el modelado (exclusión de RH como predictor para esa estación específica).
- Decisión metodológica de no imputar valores faltantes, con respaldo bibliográfico.

Camino a seguir

- Ajustar los modelos de regresión (OLS) de PM_{10} y O_3 contra las variables meteorológicas, usando el conjunto completo de predictores en NTE2 y SE3, y el conjunto reducido (sin RH) en SO.
- Aplicar Durbin-Watson para diagnosticar autocorrelación en los residuos y corregir con errores estándar HAC (Newey-West).
- Comparar los resultados entre las 3 estaciones para atender el objetivo de diferencias entre zonas, documentando explícitamente que la comparación de PM_{10} -humedad no será posible para SO.

Preguntas que han surgido

- ¿Conviene tratar la dirección del viento (WDR) como variable circular (seno/coseno) o basta con categorizarla en cuadrantes?
- ¿Qué tanto cambia la relación PM_{10}/O_3 -meteorología entre 2024 y 2025?

Liga de GitHub a la base limpia

https://github.com/D4rthCollins/Eq3_2003B/blob/trunk/base_completa.csv

Además los archivos se encuentran en el repositorio del proyecto:

https://github.com/D4rthCollins/Eq3_2003B/tree/trunk

Declaratoria de uso de IA

Opción B: se utilizó IA

1. **Herramienta:** ChatGPT, Claude
2. **Uso realizado:** Apoyo para mejorar la redacción y código en R, así como para organizar el proceso de limpieza de datos.
3. **Secciones donde se utilizó:** Redacción del reporte y preparación de los datos.
4. **Validación realizada:** El equipo revisó la información, ejecutó el código y comprobó directamente los resultados obtenidos.
5. **Responsabilidad:** El contenido final fue revisado y verificado por el equipo, que asume la responsabilidad de la información entregada.
6. **Otro:** La herramienta se utilizó como apoyo y no sustituyó la revisión.

Referencias

1. Durbin, J., & Watson, G. S. (1951). Testing for serial correlation in least squares regression II. *Biometrika*, 38(1-2), 159-179.
2. EGADE Business School. (s.f.). *Las externalidades negativas de la refinería de Cadereyta*.
<https://egade.tec.mx/es/egade-ideas/opinion/las-externalidades-negativas-de-la-refineria-de-cadereyta>
3. El Horizonte. (2025, junio 4). *Deja Ternium profunda huella... ¿de contaminación en San Nicolás!*
<https://www.elhorizonte.mx/nuevoleon/deja-ternium-profunda-huella-de-contaminacion-en-san-nicolas/9650872085>
4. Little, R. J. A., & Rubin, D. B. (2019). *Statistical analysis with missing data* (3rd ed.). Wiley.
5. Milenio. (2026, enero 19). *Sensores reportan en línea buena calidad del aire en San Pedro*.
<https://www.milenio.com/comunidad/sensores-reportan-en-linea-buena-calidad-aire-san-pedro-garza-garcia>
6. Sistema Integral de Monitoreo Ambiental (SIMA). (2018). *Programa de Respuesta a Contingencias Atmosféricas*. Secretaría de Medio Ambiente de Nuevo León.
https://aire.nl.gob.mx/docs/prc/PRC_2018.pdf

Anexos


Anexo A. Resumen general de la base de datos

Métrica	Resultado
Periodo analizado	enero 2024 - junio 2025
Estaciones	3 (NTE2, SE3 y SO)
Registros horarios esperados	39,384
Registros disponibles	39,236
Filas horarias faltantes	148
Duplicados	0
Columnas	18
Variables de medición	15
Porcentaje general de valores faltantes	4.35%


Anexo B. Horas faltantes por año y estación

Año	Estación	Horas esperadas	Registros	Horas faltantes
2024	NTE2	8,784	8,782	2
2024	SE3	8,784	8,782	2
2024	SO	8,784	8,784	0
2025	NTE2	4,344	4,343	1
2025	SE3	4,344	4,343	1
2025	SO	4,344	4,202	142

Anexo C. Matrices de correlación por estación




Anexo D. Boxplots



Anexo E. Histogramas

Distribución de los contaminantes



■ Variables categóricas

